

# Projet : Attaque et Défense dans l'apprentissage fédéré

Chuan Xu

[chuan.xu@univ-cotedazur.fr](mailto:chuan.xu@univ-cotedazur.fr)

2025

# Projet : Attaque et Défense dans l'apprentissage fédéré

Date de rendu: 17/04/2025

# Projet : Attaque et Défense dans l'apprentissage fédéré

Date de rendu: 17/04/2025

Demo Code: [https:](https://gitlab.inria.fr/chxu/fl_miage_ia_2025/-/tree/main/Projet?ref_type=heads)

[//gitlab.inria.fr/chxu/fl\\_miage\\_ia\\_2025/-/tree/main/Projet?ref\\_type=heads](https://gitlab.inria.fr/chxu/fl_miage_ia_2025/-/tree/main/Projet?ref_type=heads)

- Projet en Binôme
- Tâche: Écrivez les attaques et tester les défenses dans l'apprentissage fédéré
- Jeu de données: CIFAR 10

# Attaques

- Inversion d'étiquettes (Binôme I)
  - 1 Inverser étiquette ( $0 \rightarrow 1, 1 \rightarrow 2 \dots$ )
  - 2 L'attaquant exécute cette attaque aléatoire.
- Altération du modèle (Binôme II)
  - 1 L'asente de gradient
  - 2 L'attaquant exécute cette attaque aléatoire.

# Défenses (Binôme I et II)

- Médiane par coordonnées (FedMedian)
- Moyenne tronquée <sub>$f$</sub>  (FedTrimmedAvg)  
 $f$  indique le nombre d'attaquant. Dans FedTrimmedAvg,  $\beta$  indique la proportion d'attaquant.

# Évaluation

- 15% Code  
(avec les commentaires et le retour de fichiers qui enregistrent les statistiques) (codes pour les plots)
- 85% Rapport

# Rapport

- Introduction de l'apprentissage fédéré et FedAvg (1 point)
- Introduction les deux attaques et les deux défenses (1 point)
- Résultats (18 points)
  - ① Jeu de données, le modèle, scénario tester, la distribution de jeu de données (1 point)

# Rapport

- Résultats (18 points)

- ① Jeu de données, le modèle, scénario tester, la distribution de jeu de données (1 point)
- ② Attaques (deux figures chacun, 8 points)
  - ① Effet de nombre de attaquants dans le cas iid (2 points)
  - ② Effet de nombre de attaquants dans le cas non-iid (2 points)
  - ③ Analyses de chaque figure et Comparer les deux figures (3 points)
  - ④ Si binôme, il faut aussi compare les deux attaques (1 point)

**Attention** : chaque configuration, attaque 5 fois et montrer le résultat moyenne et aussi la déviation !



# Rapport

- Résultats (18 points)
  - ① Jeu de données, le modèle, scénario tester, la distribution de jeu de données (1 point)
  - ② Attaques (deux figures chacun, 8 points)
  - ③ Défenses (trois figures chacun, 9 points)
    - ① Effet de nombre de attaquants avec *Médiane par coordonnées* dans le cas iid (2 points)
    - ② Effet de nombre de attaquants avec *Moyenne tronquée* dans le cas iid (2 points)
    - ③ Analyses de deux figures et comparer les performances de deux défenses (2 points)

# Rapport

- Résultats (18 points)

- ① Jeu de données, le modèle, scénario tester, la distribution de jeu de données (1 point)
- ② Attaques (deux figures chacun, 8 points)
- ③ Défenses (trois figures chacun, 9 points)
  - ① Effet de nombre de attaquants avec *Médiane par coordonnées* dans le cas iid (2 points)
  - ② Effet de nombre de attaquants avec *Moyenne tronquée* dans le cas iid (2 points)
  - ③ Analyses de deux figures et comparer les performances de deux défenses (2 points)
  - ④ Effet de nombre de attaquants avec *Médiane par coordonnées* dans le cas non-iid (2 points)
  - ⑤ Analyses et comparer avec le cas iid (1 point)

# Rendu

Rendu sur Moodle (code zippé et un rapport pdf)